

# Transformada de Karhunen-Loève

Felipe Takaoka

ECA013 - f146024

*fehtakaoka@gmail.com*

5 de Setembro de 2018

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

# Introdução e Motivação

- Baseada no teorema de Karhunen–Loève da representação de um processo estocástico como uma combinação linear de funções ortogonais;
- Base que minimiza o erro quadrático e dependente do processo;
- Também conhecida como Transformada de Hotelling ou Transformada dos Autovetores;
- Intimamente relacionado com a Análise em Componentes Principais (PCA);
- Largamente utilizado em processamento digital de sinais e imagens para compressão de dados (com perdas);

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

## Definition

Uma matriz quadrada  $A$  é dita ortogonal se  $A^{-1} = A^T$ .

## Theorem

Seja  $A \in \mathbb{R}^{N \times N}$  uma matriz ortogonal. O conjunto dos seus vetores colunas  $a_i \in \mathbb{R}^N$  forma uma base ortonormal (i.e.  $\langle a_i, a_j \rangle = a_i^T a_j = \delta_{ij}$ ).

## Definition

A transformada ortogonal por  $A$  de um sinal discreto  $x \in \mathbb{R}^N$  é dada por:

$$y = A^T x$$

Ou seja,  $y_i = a_i^T x = \langle a_i, x \rangle$ . E, logo, a transformada inversa,  $x = Ay$ .

## Teorema Espectral em Dimensão Finita

Se  $A$  é uma matriz real simétrica, então  $A$  é diagonalizável por uma matriz ortogonal.

## Forma Canônica

$$A = Q\Lambda Q^{-1} = Q\Lambda Q^T$$

com  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$  a matriz diagonal dos autovalores de  $A$  e  $Q = [v_1, \dots, v_n]$  a matriz ortogonal cujas colunas são compostas pelos autovetores de  $A$



- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

## Definition

Um vetor aleatório é um vetor cujos componentes são variáveis aleatórias (V.A.).

## Sinais aleatórios

Um sinal físico pode ser considerado como um processo estocástico e uma amostragem produz, portanto, um vetor aleatório (discreto)

$$\mathbf{x} = [x_1, x_2, \dots, x_n]^T.$$

# Momentos teóricos x Momentos empíricos

Seja  $x \in \mathbb{R}^{n \times 1}$  um vetor coluna aleatório real.

## Média e Matriz de Variância(-Covariância) Teóricas

$$\mu := E(x) = [E(x_1), \dots, E(x_n)]^T = [\mu_1, \dots, \mu_n]^T$$

$$\Sigma := E[(x - \mu)(x - \mu)^T] = E(xx^T) - \mu\mu^T = \begin{bmatrix} \sigma_1^2 & \dots & \sigma_{1n}^2 \\ \vdots & \ddots & \vdots \\ \sigma_{n1}^2 & \dots & \sigma_n^2 \end{bmatrix}$$

# Momentos teóricos x Momentos empíricos

## Média e Matriz de Variância(-Covariância) Empíricas

Num total de  $n$  realizações, seja  $x_i \in \mathbb{R}^{n \times 1}$  a  $i$ -ésima realização de um vetor coluna aleatório.

$$\hat{\mu} := \frac{1}{n} \sum_{k=1}^n x_k$$

$$\hat{\Sigma} := \frac{1}{n-1} \sum_{k=1}^n x_k x_k^T - \hat{\mu} \hat{\mu}^T$$

Obs.: se  $\hat{\mu} = 0$  (facilmente obtido pela mudança de variável  $x' = x - \hat{\mu}$ )

$$\hat{\Sigma} = \frac{1}{n-1} \begin{bmatrix} | & & | \\ x_1 & \dots & x_n \\ | & & | \end{bmatrix} \begin{bmatrix} - & x_1^T & - \\ & \vdots & \\ - & x_n^T & - \end{bmatrix} = \frac{1}{n-1} (X^T X)$$

# Transformada Ortogonal de um Vetor Aleatório

## Momentos da transformada

Dados  $x$  um vetor aleatório e  $A$  uma matriz ortogonal, a transformada ortogonal  $y = A^T x$  também é um vetor aleatório com:

$$\mu_y = E(x) = E(A^T x) = A^T E(x) = A^T \mu_x$$

$$\Sigma_y = E[(y - \mu_y)(y - \mu_y)^T] = \dots = A^T \Sigma_x A$$

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

## Premissa

Se  $x = [x_1, x_2, \dots, x_n]$  é um vetor aleatório que representa as  $N$  amostras de um sinal físico contínuo, as amostras próximas tendem a ser mais correlacionadas do que aquelas mais distantes.

Em outras palavras, dado  $x_i$ , pode-se prever  $x_{i+1}$  com muito mais "confiança" do que uma amostra  $x_j$  com  $|j - i| \gg 1$ .



- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

# Definição

Dado um vetor aleatório  $x$ , denotemos por  $\phi_i$  o  $i$ -ésimo autovetor associado ao autovalor  $\lambda_i$  da matriz de variância de  $x$ ,  $\Sigma_x$ .

Desta forma, pelo teorema espectral, como  $\Sigma_x$  é real e simétrica, seus autovetores formam uma base ortogonal. Assim, é ortogonal

$$\Phi := [\phi_1, \dots, \phi_n]$$

Ou seja,  $\Phi^{-1} = \Phi^T$ . Além disso, se  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ , tem-se:

$$\Phi^{-1} \Sigma_x \Phi = \Lambda$$

## Transformada de Karhunen-Loève

$$y = \Phi^T x$$

## Transformada Inversa

$$x = \Phi y$$

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

É possível demonstrar que, dentre todas as transformações ortogonais, a KLT é ótima no sentido em que:

- 1 KLT "descorrelaciona" completamente o sinal;
- 2 KLT compacta de forma máxima a energia (informação) contida no sinal;

# Propriedade 1 - KLT "descorrelaciona" o sinal

## Momentos da Transformada

Média:

$$\mu_y = \Phi^T \mu_x$$

Matriz de variância:

$$\Sigma_y = \dots = \Phi^T \Sigma_x \Phi = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$$

$$\Sigma_y = \begin{bmatrix} \sigma_1^2 & \dots & \sigma_{1n}^2 \\ \vdots & \ddots & \vdots \\ \sigma_{n1}^2 & \dots & \sigma_n^2 \end{bmatrix} = \begin{bmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{bmatrix} = \Lambda$$

- Depois da transformada, a matriz de covariância do sinal é diagonalizada, ou seja, o sinal é "descorrelacionado";
- $\lambda_i = \sigma_i^2$

## Propriedade 2 - KLT compacta a energia

- A KLT é a transformação ortogonal que melhor "redistribui" a energia/informação contida no sinal de forma que ela seja compactada num menor número de componentes;
- Define-se a energia contida nos primeiros  $m < n$  componentes pela função:

$$S_m(A) := \sum_{i=1}^m E \left[ (y_i - \mu_{y_i})^2 \right] = \sum_{i=1}^m \sigma_{y_i}^2$$

## Propriedade 2 - KLT compacta a energia

- Para a transformação KLT:

$$S_m(\Phi) = \sum_{i=1}^m \lambda_i = \sum_{i=1}^m \sigma_{x_i}^2$$

- Desta forma, se ordenarmos os autovalores de  $\Sigma_x$  em ordem decrescente, i.e.  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m \geq \dots \geq \lambda_n$ , então estaremos maximizando  $S_m(\Phi)$ ;

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências



Tendo em mente as propriedades da KLT, podemos utilizá-la para a compressão de dados de um sinal  $x$ , fazendo-se uma redução de dimensionalidade na sua representação da seguinte maneira:

- 1 Encontre a média  $m_x$  e a matriz de covariância  $\Sigma_x$ ;
- 2 Encontre os autovetores  $\lambda_i$  de  $\Sigma_x$  ordenados de forma decrescente e os seus autovalores correspondentes;
- 3 Fixe uma porcentagem de perda de informação admissível (equiv. porcentagem mínima de informação contida do sinal original), e.g. 95%, e escolha o menor  $m < n$  tal que:

$$\frac{\sum_{i=1}^m \lambda_i}{\sum_{i=1}^n \lambda_i} = \frac{\sum_{i=1}^m \sigma_{x_i}^2}{\sum_{i=1}^n \sigma_{x_i}^2} \geq 95\%$$

- 4 Construa a matriz de transformação  $n \times m$  composta pelos autovetores ordenados de acordo com os seus respectivos autovalores:

$$\Phi_m = [\phi_1, \dots, \phi_m]_{n \times m}$$

- 5 Aplique a transformação ortogonal KLT:

$$y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}_{m \times 1} = \Phi_m^T x = \begin{bmatrix} - & \phi_1^T & - \\ & \vdots & \\ - & \phi_m^T & - \end{bmatrix}_{m \times n} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}_{n \times 1}$$

- 6 Reconstrua  $x$  aplicando a transformada KLT inversa:

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}_{n \times 1} = \Phi_m y = \begin{bmatrix} | & & | \\ \phi_1 & \dots & \phi_m \\ | & & | \end{bmatrix}_{n \times m} \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}_{m \times 1}$$

# Construção para Imagens

Dado  $N$  imagens de dimensão  $(r, c)$  com  $K = rc$  pixels cada uma, seja  $x_{c_i} \in \mathbb{R}^K$  o vetor coluna cujos componentes representam os pixels da imagem  $i$ . Desta maneira, construímos a matriz  $X \in \mathbb{R}^{K \times N}$  concatenando os vetores colunas de cada imagem:

$$X_{K \times N} = \begin{bmatrix} | & & | \\ x_{c_1} & \dots & x_{c_N} \\ | & & | \end{bmatrix} = \begin{bmatrix} - & x_{r_1}^T & - \\ & \vdots & \\ - & x_{r_K}^T & - \end{bmatrix}$$

Assim,  $x_{r_i} \in \mathbb{R}^N$  é o vetor coluna cujas componentes representam os valores dos pixels na mesma posição dos  $N$  diferentes canais/imagens.

# Construção para Imagens

Assume-se, sem perda de generalidade, que os vetores  $x_{c_i}, \forall i \in \{1, \dots, K\}$  e  $x_{r_j}, \forall j \in \{1, \dots, N\}$  têm média nula. Desta maneira, a KLT pode ser aplicada de duas formas diferentes a depender do que é tratado como realização do evento aleatório:

K realizações do vetor  $x_{r_i} \in \mathbb{R}^N$

Dada uma imagem  $i$ , os valores de seus pixels em todas as coordenadas são as realizações.

N realizações do vetor  $x_{c_j} \in \mathbb{R}^K$

Dada uma localização de um pixel, os valores de seus pixels nos diferentes canais/imagens são as realizações.

# Construção para Imagens

$K$  realizações do vetor  $x_{r_i} \in \mathbb{R}^N$

$$\Sigma_r = \frac{1}{K-1}(X^T X)$$

Se  $U$  denota a matriz ortogonal dos autovetores ordenados, a transformada KLT pode ser aplicada a cada um dos  $K$  vetores linhas de  $X$ :

$$y_{r_i} = U^T x_{r_i} \implies Y^T = U^T X^T \iff Y = XU$$

$N$  realizações do vetor  $x_{c_j} \in \mathbb{R}^K$

$$\Sigma_c = \frac{1}{N-1}(XX^T)$$

Se  $V$  denota a matriz ortogonal dos autovetores ordenados, a transformada KLT pode ser aplicada a cada um dos  $N$  vetores colunas de  $X$ :

$$z_{c_j} = V^T x_{c_j} \implies Z = V^T X$$

## Theorem

*Os problemas dos autovalores associado às duas matrizes de covariância  $\Sigma_r$  e  $\Sigma_c$  são equivalentes no sentido em que produzem o mesmo conjunto de autovalores e seus autovetores associados satisfazem a relação  $V = XU$ .*

## Corolário

A escolha da resolução do problema do autovalor pode ser feita para aquela com menor dimensão

- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

- Tendo em mente que não é necessário representar fielmente uma imagem pelo seus  $K$  pixels, podemos reduzir sua dimensionalidade de forma a diminuir seu espaço de armazenamento. Consequentemente, algoritmos de classificação de objetos em imagens, como redes neurais, se beneficiam amplamente desta representação em um espaço de dimensão reduzida;




# Aplicações - Reconhecimento de Imagens

## Eigenfaces and face recognition

Twenty images of faces ( $N = 20$ ):



The eigen-images after KLT:



# Aplicações - Reconhecimento de Imagens

Percentage of energy contained in the


components	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
percentage energy	48.5	11.6	6.1	4.6	3.8	3.7	2.6	2.5	1.9	1.9	1.8	1.6	1.5	1.4	1.3	1.2	1.1	1.1	0.9	0.8
accumulative energy	48.5	60.1	66.2	70.8	74.6	78.3	81.0	83.5	85.4	87.3	89.	90.7	92.2	93.6	94.9	96.1	97.2	98.2	99.2	100.0

Reconstructed faces using 95% of the total information (15 out of 20 components):



# Aplicações - Alinhamento de objetos

- Para imagens binárias, é possível alinhar objetos bidimensionais ao longo do seu autovetor principal (associado ao maior autovalor), o que pode ser importante para reconhecimento de objetos;



- 1 Introdução e Motivação
- 2 Revisão e notações
  - Álgebra Linear
  - Estatística e Processos Estocásticos
- 3 Transformada de Karhunen-Loève
  - Premissa
  - Definição
  - Propriedades
  - Construção
- 4 Aplicações
- 5 Referências

- <http://fourier.eng.hmc.edu/e161/lectures/klt/klt.html>
- <http://www.dca.fee.unicamp.br/~lotufo/cursos/ia-636-2000/labs/5rsoares/lab12/index.html>
- [https://en.wikipedia.org/wiki/Karhunen-Loeve\\_theorem](https://en.wikipedia.org/wiki/Karhunen-Loeve_theorem)
- [https://pt.wikipedia.org/wiki/Matriz\\_ortogonal#cite\\_note-7](https://pt.wikipedia.org/wiki/Matriz_ortogonal#cite_note-7)
- [https://en.wikipedia.org/wiki/Symmetric\\_matrix](https://en.wikipedia.org/wiki/Symmetric_matrix)
- ROUVIÈRE, L. Statistique - Notes de Cours. CentraleSupélec, 2016.
- RICHARD, P.Y. Représentation et analyse statistique des signaux - Notes de Cours. CentraleSupélec, 2016.